

Implementação de um perceptron para classificar dados da base Iris.

Murielly Oliveira Nascimento

16 de outubro, 2023

Uma das áreas de pesquisa que recebeu mais atenção nas últimas décadas é a Inteligência Artificial. Grandes esforços têm sido aplicados na tentativa de criar máquinas capazes de apresentar comportamentos humanos. Sabendo que a inteligência do homem deriva do cérebro, cujas entidades básicas são os neurônios, pesquisadores tentam copiar tal estrutura e funcionamento em um ambiente técnico, o que recebeu o nome de Redes Neurais Artificiais (RAUBER, 2008).

(ROSENBLATT, 1958) propôs um sistema eletrônico que aprenderia a reconhecer similaridades ou identidades entre padrões óticos, elétricos, ou sonoros de uma maneira que poderia ser aproximadamente análoga aos processos de percepção do cérebro. Tal sistema dependeria de princípios probabilísticos e ganharia confiança a partir de propriedades de medidas estatísticas obtidas de uma grande população de elementos. O sistema que seguisse esses princípios se chamaria *perceptron*. Em poucas palavras, o *perceptron* é uma rede neural com uma camada.

Os valores de entrada de um *perceptron* são coletivamente chamados de vetor de entrada. Analogamente, os valores de peso são chamados de vetor de pesos, os quais, inicialmente, são inicializados aleatoriamente; é durante o treinamento do *perceptron* que os pesos ideais são aprendidos pela rede neural (GOODFELLOW; BENGIO; COURVILLE, 2016).

Neste trabalho a rede neural *perceptron* foi implementada para a classificação da base de dados Iris. A mesma contém informações sobre três variedades da planta iris: *Setosa*, *Versicolour* e *Virginica*. As características que as separam são: comprimento da sépala, largura da sépala, comprimento da pétala e largura da pétala.

Na Tabela 1 são descritos os testes para a classificação de 100 instâncias da base de dados Iris, com as espécies *Setosa* e *Versicolour*. O ponto de partida é: número de iterações ou *epochs* (100), taxa de aprendizado ou *learning rate* (1%) e conjunto de teste (10%), o que significa que 90% dos dados foram usados para treinar o *perceptron*. Nos demais testes os parâmetros são alterados com o intuito de aumentar a acurácia — proximidade entre o valor obtido experimentalmente e o valor verdadeiro na medição de uma grandeza física (OXFORD..., 2023) — do algoritmo.

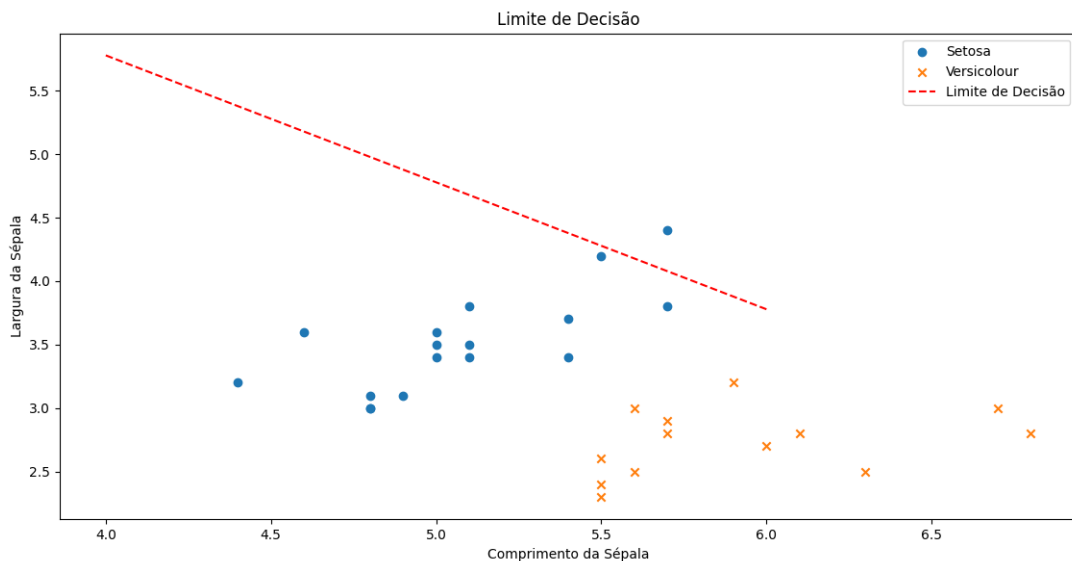
Observa-se que a configuração, número de iterações ou *epochs* (200), taxa de aprendizado ou *learning rate* (1%) e conjunto de teste (30%) apresentou a melhor acurácia (0.46). Enquanto a configuração inicial, descrita na primeira linha da tabela, obteve o pior resultado (0.4 de acurácia).

Tabela 1 – Testes com 2 espécies da base Iris.

Medidas de Avaliação.			
Iterações	Taxa de Aprendizado	Conjunto de Teste	Acurácia.
100	1%	10%	0.4
100	1%	30%	0.43
200	1%	30%	0.46
300	1%	30%	0.46
200	2%	30%	0.43
200	3%	30%	0.43
200	4%	30%	0.43
200	5%	30%	0.46
300	1%	70%	0.44

A Figura ?? ilustra o Limite de Decisão para com esta configuração. Nela a linha que desenha o limite de decisão ficou incompleta.

Figura 1 – Limite de Decisão.



Na Tabela 2 são descritos os testes para a classificação de todas as instâncias da base de dados Iris, incluindo as três espécies, *Setosa*, *Versicolour* e *Virginica*. O vetor de pesos é o mesmo dos testes realizados na 1, ou seja, o conjunto de dados para treino possui as duas espécies, já o conjunto de testes inclui todas as três. O ponto de partida é a melhor configuração encontrada na Tabela 1. Nesta Tabela (2), a acurácia conseguiu atingir no máximo 0.32, isso se deve ao acréscimo da terceira espécie de Iris.

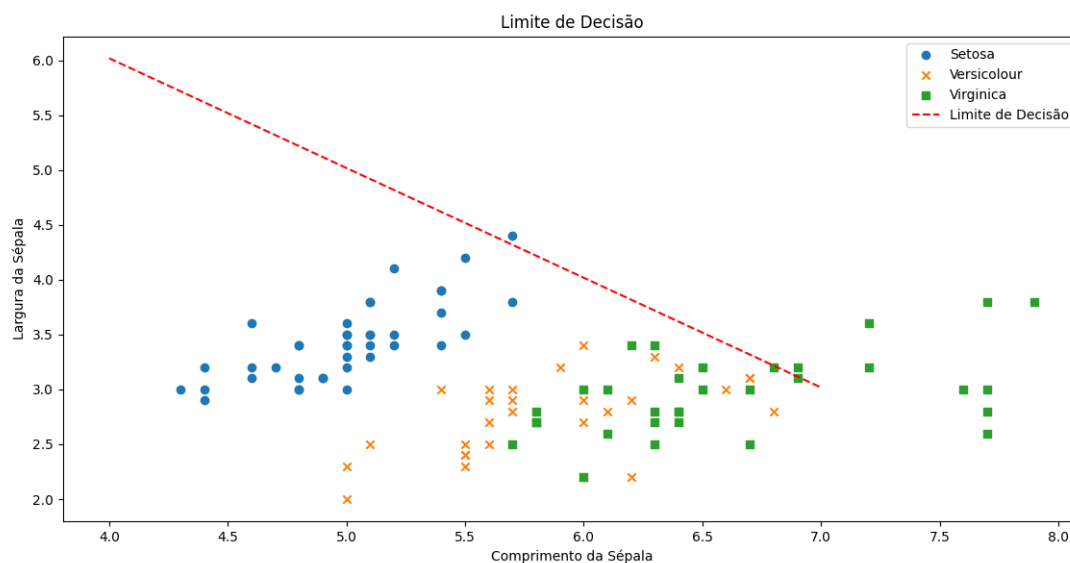
A Figura 2 ilustra o Limite de Decisão para com a melhor configuração. Nela a

Tabela 2 – Testes com 2 espécies da base Iris.

Medidas de Avaliação.			
Iterações	Taxa de Aprendizizado	Conjunto de Teste	Acurácia.
200	1%	30%	0.26
200	1%	50%	0.29
200	1%	70%	0.31
200	2%	70%	0.31
200	3%	70%	0.31
300	1%	70%	0.32
300	2%	70%	0.31
300	3%	70%	0.30
300	4%	70%	0.31

linha que desenha o limite de decisão ficou incompleta. Sendo que o Limite de Decisão continua separando as duas espécies (Setosa e Versicolor) e ignora a espécie Virgínica.

Figura 2 – Limite de Decisão.



Logo, para classificação de dados em mais de 2 grupos, o *perceptron* apresenta problemas, como demonstrado nos testes com a base de dados Iris. Embora, apresente resultados relativamente bons para conjunto de dados com 2 itens e seja de fácil implementação, levando em conta os poucos parâmetros usados: taxa de aprendizado, iterações e tamanho do conjunto teste. Além disso, é um bom ponto de partida para estudantes que estejam aprendendo sobre Redes Neurais Artificiais.

Referências

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016. <<http://www.deeplearningbook.org>>. Citado na página 1.

OXFORD Dicionário Português. 2023. <<https://languages.oup.com/google-dictionary-pt/>>. Accessed on 19/10/2023. Citado na página 1.

RAUBER, T. W. *Redes Neurais Artificiais*. Artigo — Universidade Federal do Espírito Santo, 2008. Citado na página 1.

ROSENBLATT, F. *The Perceptron*. Artigo — Cornell Aeronautical Laboratory, 1958. Citado na página 1.